

第 1 章 常用符号表

表 1.1: 基于马尔可夫随机游走的模糊粒异常检测符号表

DS	数据集
U	非空对象有限集
A	非空属性有限集
B	属性子集
R_B	关于 B 在 U 上的模糊关系
$G(R_B)$	R_B 可诱导 U 的模糊粒结构
$[o_i]_B$	对象 o_i 的模糊粒向量
$ [o_i]_B $	$[o_i]_B$ 的基数
$[o]_B(p)/R_B(o, p)$	在属性集合 B 下 o 和 p 之间的模糊相似关系
σ	可调参数
(Ω, F, PR)	概率空间, 其中 Ω 为样本空间, F 为随机事件集, PR 为概率
X	随机过程, 满足条件概率分布则为离散时间马尔可夫链
$\mathbf{P}$	状态转移矩阵
π	平稳分布, 概率向量
$FGD(o, p)$	o 与 p 之间的模糊粒距离
$\mathbf{D}$	模糊粒距离构成的矩阵
$\mathbf{E}$	对角矩阵

表 1.1 (续)

e_i	第 i 个对角元素
d	阻尼因子
$ASC(o_i)$	每个样本的异常得分
E	对角矩阵
e_i	第 i 个对角元素
d	阻尼因子
$ASC(o_i)$	每个样本的异常得分

表 1.2: 基于属性粒的对象熵的异常检测符号表

CF	形式背景
OB	非空有限对象集
AT	非空有限属性集
$I/I(o, a)$	OB 和 AT 之间的二元关系
a	属性
o	对象
CO	对象子集
CA	属性子集
CO^*	CO 在 (OB, AT, I) 中的对象内涵
CA^*	CA 在 (OB, AT, I) 中的属性外延
(CO, CA)	形式概念
$L(OB, AT, I)$	概念格
$L_{OB}(OB, AT, I)$	所有外延组成的集合
$L_{AT}(OB, AT, I)$	所有属性组成的集合
CO^{**}	包含 CO 的最小外延
CA^{**}	包含 CA 的最小内涵
$(o^{**}, o^*)/\{o\}^*$	对象概念
$(a^*, a^{**})/\{a\}^*$	属性概念
CC	属性子集
$CF_{CC} = (OB, C, I_{CC})$	形式背景 $CF = (OB, AT, I)$ 的形式子背景
I_{CC}	OB 与 CC 之间的二元关系

表 1.2 (续)

CO^{*CC}	所有对象 CO 共同具有的 CC 中的最大属性集
CA^{*CC}	具有 CC 中所有属性的 CA 的最大对象集
CV	对象子集
I_{CV}	CV 与 AT 之间的二元关系
$CF_{CV} = (CV, AT, I_{CV})$	面向对象形式子背景
CO^{*CV}	所有对象 CO 共同具有的 CV 中的最大属性集
CA^{*CV}	具有 CV 中所有属性的 CA 的最大对象集
$OE(CO)/OE(F_{CO})$	CO 在 CF_{CO} 下基于属性粒的对象熵
$OE(CO, CP)$	CO 与 CP 之间基于属性粒的对象联合熵
$OE(CP CO)$	基于属性粒的 CO 关于 CP 的对象条件熵
$OMI(CP; CO)$	基于属性粒的 CO 与 CP 之间的对象互信息
$Corr(o_i)$	对象 o_i 的相关性
OS_u	当前未被选中的对象集合
OS_{r-1}	已选中的 $(r - 1)$ 个对象组成的集合
$Corr(o_{i_k} o)$	已选对象 o_{i_k} 相对于候选对象 o 的条件相关性
$Aggr(o, o_{i_k})$	候选对象 o 与已选对象 o_{i_k} 之间的聚合度
o_{i_r}	最小相关度 - 最大聚合度的对象异常评估指标
$W(o)$	权重函数
$Score(o_{i_k})$	o_{i_k} 的异常值分数

表 1.3: 基于模糊 k NN 熵的异常检测符号表

U	非空有限对象集
C	非空有限属性集
V	属性取值域的并集
$\tilde{C}$	U 上的模糊集
$\tilde{C}(o)$	$\forall o \in U$ 在 $\tilde{C}$ 中的隶属度
$\tilde{F}(U)$	U 上所有模糊集的集合
$\widetilde{M} \cup \widetilde{N}$	$\widetilde{M}(o) \vee \widetilde{N}(o)$, $\widetilde{M}$ 与 $\widetilde{N}$ 的并集
$\widetilde{M} \cap \widetilde{N}$	$\widetilde{M}(o) \wedge \widetilde{N}(o)$, $\widetilde{M}$ 与 $\widetilde{N}$ 的交集
$\tilde{R}$	U 上的模糊相似关系
$\tilde{R}_B$	U 上关于 B 的模糊相似关系
$M_{\tilde{R}_B}$	模糊相似关系矩阵
$G_U(\tilde{R}_B)$	由模糊相似关系 $\tilde{R}_B$ 推导出的模糊粒结构
$[o_i]_{\tilde{R}_B}$	由模糊相似关系 $\tilde{R}_B$ 诱导的包含 o_i 的模糊信息粒
$[o_i]_{\tilde{R}_B}(o_j)/\tilde{R}_B(o_i, o_j)/r_{ij}^B$	表示 o_j 对 $[o_i]_{\tilde{R}_B}$ 的隶属程度
$ [o_i]_B $	模糊集 $[o_i]_{\tilde{R}_B}$ 的基数
$FE(B)/FE(\tilde{R}_B)$	$\tilde{R}_B$ 的模糊信息熵
$FNE(B, \lambda)/FNE(\tilde{R}_B^\lambda)$	以 λ 为邻域半径的关于 B 的模糊邻域熵
$D_B(o_i, o_j)$	对象 o_i 与 o_j 在集合 B 中的距离
$K_{simi}(o_i)$	对象 o_i 的 k 相似度
$[o_i]_{\tilde{R}_B^k}(o_j)$	对象 o_i 的模糊 k 最近邻
$M_{\tilde{R}_B}^k$	模糊 k 相似性关系矩阵

表 1.3 (续)

$FkE(B)/FkE(\tilde{R}_B^k)$	$\tilde{R}_B$ 的模糊 k NN 熵
$FkE(\tilde{R}_{B_1}^k, \tilde{R}_{B_2}^k)$	$\tilde{R}_{B_1}^k$ 与 $\tilde{R}_{B_2}^k$ 的模糊 k 联合熵
$FkE(\tilde{R}_{B_2}^k \tilde{R}_{B_1}^k)$	$\tilde{R}_{B_2}^k$ 相对于 $\tilde{R}_{B_1}^k$ 的模糊 k 条件熵
$FkMI(\tilde{R}_{B_1}^k; \tilde{R}_{B_2}^k)$	$\tilde{R}_{B_2}^k$ 与 $\tilde{R}_{B_1}^k$ 的模糊 k 互信息
$RFkE_B(o)$	基于 $\tilde{R}_B^k$ 的对象 o_i 的相对模糊 k NN 熵
$FkE_o(B)$	在模糊相似关系 $\tilde{R}_B^k$ 下, 从论域 U 中移除对象 o 后的模糊 k NN 熵
$RFkC_B([o])$	模糊相似关系 $\tilde{R}_B^k$ 的相对模糊 k 基数
AS	属性序列
ASS	属性子集序列
$FkAD_B(o)$	对象 o 的模糊 k 关系异常度
W_B^k	权重函数
$FkEAF(o)$	o 的模糊 k NN 熵基异常因子

表 1.4: 基于自然邻居比率熵的异常检测符号表

U	非空有限对象集
C	非空有限属性集
V	属性取值域的并集
f	$f : U \times C \rightarrow V$, 表示信息函数
o	具体对象
ε	邻域半径
$n_p(o_i)$	对象 o_i 相对于 P 的邻域
nr_P	U 上关于 P 的邻域关系
$Cover(nr_P)$	U 上的邻域知识
NR_C	U 上的所有邻域关系集合
NIS	邻域信息系统
$NH^{o_i}(P)$	对象 o_i 在 P 上的邻域不确定性
$ \cdot $	集合 $\cdot$ 的基数
$NE(P)$	P 上的邻域熵
$k_{dist}(p)$	点 p 的 k 距离
$kNNS_P(o_i)$	k -最近邻域子集
λ_P	自然邻居特征值
$NNAM$	自然邻居邻接矩阵
$NaNGS$	自然邻居粒
$NaNE$	自然邻居熵
$NaNRE$	自然邻居比率熵

表 1.4 (续)

$NaN_P(o_i)$	o_i 的自然邻居类
$NNAM_P[o_i, o_j]$	自然邻居邻接矩阵
$cNaN_E(Q P)$	自然邻居条件熵
$NaNMI(P; Q)$	自然邻居互信息
$NaN_E(P, Q)$	属性子集 P 和 Q 的自然邻居联合熵
$W_P(o_i)$	权重函数
AS	属性序列
c'_1	属性序列的元素
AFS	属性子集前向序列
C_1	属性子集反向序列的元素
ARS	属性子集反向序列
C'_1	属性子集反向序列的元素
$MNES$	自然邻居熵序列
$FMNES$	自然邻居熵前向序列
$RMNES$	自然邻居熵反向序列
ERM_{AS}	自然邻居比率熵矩阵
ERM_{AFS}	自然邻居比率熵前向矩阵
ERM_{ARS}	自然邻居比率熵反向矩阵
WM_{AS}	权重函数矩阵
WM_{AFS}	权重函数前向矩阵
WM_{ARS}	权重函数反向矩阵

表 1.4 (续)

$AERM$	平均自然邻居比率熵矩阵
AWM	平均权重函数矩阵
$NaNCEAF$	异常因子
μ	判断阈值

第 2 章 基于自然邻居比率熵的异常检测

摘要：随着邻域粗糙集理论在异常检测中的成功应用，多种检测方法都能够取得出色的检测结果。然而现有的邻域粗糙集算法依赖于人工设定邻域半径参数，难以适应结构复杂的数据集。针对这一不足，本文将自然邻居这一无参方法的思想引入邻域粗糙集，提出了自然邻居比率熵及其相关不确定性度量，并根据这一理论设计了基于自然邻居比率熵的异常检测模型。首先，定义了自然邻居搜索和自然邻居邻接矩阵，然后，提出了自然邻居熵和自然邻居比率熵，以及自然邻居联合熵、自然邻居条件熵、自然邻居互信息等相关不确定性度量。基于所提理论，构建了自然邻居比率熵异常检测模型。首先，基于所提理论中的自然邻居邻接矩阵来无参化自适应地构建了自然邻居粒结构，并定义了自然邻居熵和自然邻居比率熵以表征数据对象的不确定性。接着，定义了三种不同的属性序列，构建了平均自然邻居比率熵矩阵与平均权重函数矩阵，以表明数据对象的异常程度。最后，设计了相应的基于自然邻居比率熵的异常检测算法（NaNREAD）。该算法在 15 个公开数据集上与近些年的 10 个优秀算法进行了对比实验，结果表明自然邻居比率熵异常检测模型效果更好，可成功应用于异常检测任务。

2.1 引言

异常检测，目的是找出数据中与其他数据存在显著差异的对象^[1-2]。它在现实世界中有着广泛的应用场景，比如金融异常事件、网络入侵以及医疗诊断等^[3-5]。准确地识别出这些偏离常规模式的异常值，对于规避潜在风险和系统初筛缺陷有重要意义。

粗糙集理论（Rough Set Theory, RST）作为处理不充分、不完备数据的有效数学工具，已被成功应用于异常检测任务^[2,6-13]。但经典粗糙集理论基于等价关系构建数学模型，仅适用于标称型属性数据，处理数值型属性数据时需要先进行离散化操作，这会增加时间开销并产生严重的信息缺失。为了有效处理混合类型的数据，有学者将邻域关系引入了粗糙集理论中。Lin^[14] 将邻域和邻域关系引入了粗糙集理论；Yao^[15] 研究了邻域近似空间的性质；Hu 等人^[16-18] 提出了邻域粗糙集模型并给出了一些特征选择算法。邻域粗糙集是一种强大的数据挖掘工具^[2]，它用邻域关系替代了经典粗糙集中的等价关系，可以直接处理数值型数据和混合型数据。

随着邻域粗糙集理论在异常检测中的成功引用，多种检测方法都能够取得出色的检测结果^[2,19-22]。例如，Chen 等人^[19-22] 将邻域模型作为统一框架构建邻域异常检测；近期，Yuan 等人^[20] 基于邻域熵提出了一种混合数据驱动的异常检测方法；Wang 和 Li^[21] 在邻域粗糙集中提出了一种基于加权网络模型的混合值数据集异常检测方法；文献^[22] 中采用基于邻域粗糙集的方法检测原型异常值。

然而，现有的邻域粗糙集算法依赖于人工设定邻域半径参数，一旦参数发生变化，

异常检测结果便会呈现明显差异。因此,参数选取对异常检测算法至关重要。然而,在实际应用中,参数确定往往依赖研究者的经验积累与大量反复实验。这使得算法的主观性和随机性强,参数设置的敏感性也导致算法难以适应结构复杂的数据集。

自然邻居思想也可以作为一种基于聚类的方法应用于异常检测中,优势在于它可以根据数据对象的局部密度信息自动确定其邻居,不需要人为设置参数^[23]。自然邻居是指与目标数据对象在相同或相似密度水平上的数据对象,它们可以更好地反映目标数据对象所属的簇或类别。然而,将自然邻居思想融入于邻域粗糙集理论并应用于异常检测的方法并未被提出。因此,为了解决基于有参异常检测方法的难点——如何定义和度量数据点之间的相似性或距离,如何定义和度量正常和异常的标准,如何处理高维和复杂的数据以及如何确定合适的参数,本文首次将自然邻居思想与粒计算结合并应用到异常检测领域,提出了一种基于自然邻居比率熵的异常检测 (Natural Neighbor Ratio Entropy Anomaly Detection, NaNREAD) 方法。

本文的主要工作如下:首先,定义了自然邻居搜索和自然邻居邻接矩阵。基于自然邻居邻接矩阵,无参自适应地构建了自然邻居粒结构,并定义了自然邻居熵和自然邻居比率熵;随后,提出相关信息论度量。在此理论基础上,构建自然邻居比率熵异常检测模型:首先定义三种不同的属性序列;其次,基于属性序列和权重函数,分别定义三种自然邻居比率熵矩阵和权重函数矩阵;然后,构建基于平均自然邻居比率熵和平均权重的异常因子;最后,设计了相应的基于自然邻居比率熵的异常检测算法 (NaNREAD)。

为了验证所提算法的有效性,我们在 15 个公开数据集上,将 NaNREAD 算法与近些年的 10 个优秀异常检测算法进行了详尽的对比实验。实验结果表明,自然邻居比率熵异常检测模型能够有效克服传统算法对人工参数设定的依赖,展现出了更优越、更稳定的异常检测性能,可成功应用于各类异常检测任务。

本文的其余部分安排如下:第 2.2 节详细阐述自然邻居搜索过程、自然邻居比率熵及其相关不确定性度量理论;第 2.3 节基于所提理论构建完整的异常检测模型;第 2.4 节给出具体的 NaNREAD 算法描述与复杂度分析;第 2.5 节提供一个详细的算法计算示例说明;第 2.6 节展示并深入分析多维度的对比实验结果;最后对本文内容进行总结。

2.2 自然邻居比率熵及其相关度量

本节将自然邻居思想引入邻域粗糙集中进行自适应粒化,构建自然邻居信息系统并得到自然邻居粒,提出自然邻居比率熵及其相关度量。

2.2.1 邻域粗糙集

本小节回顾邻域粗糙集中邻域信息系统 (NIS) 和邻域熵的相关知识^[17,24]。

定义 2.2.1. 无决策信息系统中 $NIS = (U, C, V, f)$, 有非空有限对象集 $U = \{o_1, \dots, o_n\}$

；非空的有限属性集 C ； $V = \sum_{c \in C} V_c$ 是属性域 V_c 的并集； $f : U \times C \rightarrow V$ 表示信息函数，满足对任意 $o \in U$ 和 $c \in C$ ，有 $f(o, c) \in V_c$ 。

定义 2.2.2. 对于 $\forall o_i, o_j, o_k \in U$ ， $P \subseteq C$ 上的距离函数 $d_P : U \times U \rightarrow [0, \infty)$ ，满足：

- 1) 非负性： $d_P(o_i, o_j) \geq 0$ ，且 $d_P(o_i, o_j) = 0$ 当且仅当 $o_i = o_j$ ；
- 2) 对称性： $d_P(o_i, o_j) = d_P(o_j, o_i)$ ；
- 3) 三角形不等式： $d_P(o_i, o_k) \leq d_P(o_i, o_j) + d_P(o_j, o_k)$ 。

距离度量的方法有很多种，本文选用闵可夫斯基距离，其距离函数的定义如下：

$$d_P^q(o_i, o_j) = \sqrt[q]{\sum_{a \in P} |f(o_i, a) - f(o_j, a)|^q}. \quad (2-1)$$

如果 q 取 1， d_P 可被称为曼哈顿距离。 q 取 2，则是欧几里得距离。 q 取 ∞ ，则是切比雪夫距离^[25]。本文中默认采用 $q = 2$ 的欧几里得距离作为相似性度量方式。

由于等价关系和等价类仅适用于处理标称型属性数据集，因此通过在距离度量的基础上引入邻域半径 ε 对论域 U 进行粒化，能够形成邻域和邻域类，这样就用邻域关系替代了只适用于标称型属性数据的等价关系，能够有效处理数值型和混合型属性数据。为此，构建邻域信息系统。

定义 2.2.3. 对于任意 $P \subseteq C$ ，对象 o_i 关于 P 的邻域 $n_P(o_i)$ 定义为：

$$n_P(o_i) = \{o_j | d_P(o_i, o_j) \leq \varepsilon_P, o_j \in U\} \quad (2-2)$$

$n_P(o_i)$ 包含了论域 U 中与 o_i 在 P 上的距离不超过 ε 的所有对象，是基于距离的邻域粒。

进一步地，定义 $nr_P = \{(o_i, o_j) | o_i, o_j \in U, o_j \in n_P(o_i)\}$ 为 U 上关于 P 的邻域关系。显然，邻域关系满足自反性和对称性，属于相似关系。特别地，当 $\varepsilon_P = 0$ 时， nr_P 表示 U 上的等价关系，适用于标称型属性数据；当 $\varepsilon_P > 0$ 时， nr_P 表示 U 上的相似关系，适用于数值型属性数据。

$Cover(nr_P)$ 表示 U 的一个覆盖，称为 U 上的邻域知识。令 $NR_C = \{nr_P | P \subseteq C\}$ 表示 U 上的所有邻域关系，则四元组 $NIS = (U, NR_C, V, f)$ 称为邻域信息系统。

显然，不同的距离度量和 ε 会得到不同的邻域信息系统。当 $\varepsilon_P = 0$ 时， o_i 的邻域类退化为 o_i 的等价类，即 $n_P(o_i) = [o_i]_P$ ，此时邻域信息系统退化为经典信息系统。

Hu 等人提出的邻域熵能够同时处理标称型和数值型属性数据^[24]，定义如下：

定义 2.2.4. 对象 o_i 在 P 上的邻域不确定性计算为：

$$NH^{o_i}(P) = -\log_2 \frac{|n_P(o_i)|}{|U|} \quad (2-3)$$

其中 $|\bullet|$ 表示集合 $\bullet$ 的基数。

定义 2.2.5. P 上的邻域熵 $NE(P)$ 定义为:

$$NE(P) = -\frac{1}{|U|} \sum_{i=1}^{|U|} \log_2 \frac{|n_P(o_i)|}{|U|}. \quad (2-4)$$

在上述定义中, 邻域熵通过每个对象邻域的平均不确定性计算得到, 能够衡量邻域粗糙集的不确定性。若 nr_P 退化为清晰等价关系, 则所提邻域熵与经典香农熵一致, 为混合属性异常检测方法的构建奠定了理论基础^[26]。

2.2.2 自然邻居搜索算法

本小节构建用于异常检测的自然邻居信息系统, 并提出自然邻居熵及其相关度量。

邻域系统中需要设定半径, 而邻域半径需根据经验确定^[17,19,24]。如, Chen 等人的模型半径参数数量将与属性数量 m 相同^[19], 使得模型对参数敏感。并且降低算法的参数敏感性是提高算法准确性的基础^[2], 因此现有算法大多采用的是融合属性值实际分布与专家经验来设置半径^[20,26], 但仍然无法避免需要数据集的先验知识和参数依赖严重的问题。为此, 本文引入自然邻居搜索算法确定自然邻居, 自适应地确定自然邻居粒, 无需人为设定参数。

定义 2.2.6. 对于对象集 U , $P \subseteq C$ 有 $p \subseteq U, o \subseteq U$ 。点 p 的 k 距离 (k -distance) 被定义为:

$$k_{dist}(p) = d_P^2(p, o) \quad (2-5)$$

1) 令 $d(p, o') \leq d(p, o)$, 最少有 k 个对象 $o' \in U \setminus \{p\}$;

2) 令 $d(p, o') < d(p, o)$, 最多有 $(k-1)$ 个对象 $o' \in U \setminus \{p\}$;

定义 2.2.7. ^[23] 对于对象集 U , $P \subseteq C$, $kNNS_P(o_i)$ 是在任意属性子集 P 下的一个 k -最近邻域子集 (k -Nearest Neighborhood Subset, $kNNS$), 公式定义为:

$$kNNS_P(o_i) = \{X \in D \setminus \{o_i\} | d_P^2(o_i, X) \leq k_{dist}(o_i)\}. \quad (2-6)$$

$kNNS_P$ 指的是一个点的若干邻域构成的集合, 如果这个集合满足一定的条件, 就称为这个点的一个邻域基。需要提醒的是, 对象 o_i 的最近邻域子集的对象数量可能大于 k 。换句话说, $kNNS_P(o_i)$ 中可能有多于 k 个对象。

定义 2.2.8. ^[27] 自然邻居搜索过程达到自然搜索稳定状态 (Natural Search Stable State, NSSS) 时满足:

$$(\forall o_i)(\exists o_j)(k \in \mathbb{N}) \wedge (o_i \neq o_j) \rightarrow (o_i \in kNNS_P(o_i)) \wedge (o_j \in kNNS_P(o_i)). \quad (2-7)$$

对于数据集 U , 当 k 由 1 开始逐渐递增, 依次对数据集 U 进行 kNN 搜索, 搜索过程中, 如果 k 增至 λ 时, U 中任意点都至少存在一个点与之互为邻居, 则把当前搜索状态称为 NSSS^[23]。也就是说, 当两个样本点均在各自的 k -最近邻域子集中时, 称这两个对象互为邻居。

定义 2.2.9. ^[27] 对于 $P \subseteq C$, 当自然邻居搜索算法达到自然搜索稳定状态时, 自然邻居特征值 λ_P 即为当前搜索的 k 值。

$$\lambda_P \triangleq k_{k \in \mathbb{N}} \{k \mid (\forall o_i)(\exists o_j)(k \in \mathbb{N}) \wedge (o_i \neq o_j) \rightarrow (o_i \in kNNS_P(o_i)) \wedge (o_j \in kNNS_P(o_i))\}. \quad (2-8)$$

定义 2.2.10. ^[27] 对于数据集 U , 对于 $P \subseteq C$, 样本点 o_i 的自然邻居定义为:

$$o_j \in NaN_P(o_i) \Leftrightarrow (o_i \in kNNS_P(o_j)) \wedge (o_j \in kNNS_P(o_i)), \quad (2-9)$$

其中, $NaN_P(o_i)$ 表示样本点 o_i 在属性子集 P 下的自然邻居搜索的结果, 即 o_i 的自然邻居类。

传统的 k -最近邻和自然邻居之间的一个显著区别是自然邻居需要满足互为 k -最近邻, 因而自然邻居集合中邻居的数量也会相应地变化, 与传统的 k -最近邻不一样。因此, 可以通过这种自然的方式从数据集中提取更多有趣的信息。

定义 2.2.11. ^[27] 对于数据集 U , $P \subseteq C$, 经自然邻居搜索达到自然搜索稳定状态后, 将此时获得的样本点以及对应的邻居视作一个无向图, 同时使用邻接矩阵进行图表示, 以每个样本点作为图节点, 若两个样本点间互为邻居, 则认为两个点间存在一条边, 对于自然邻居邻接矩阵 (Natural Neighbor Adjacency Matrix, NNAM), 定义为:

$$NNAM_P[o_i, o_j] = 1 \text{ 如果 } o_j \in NaN_P(o_i). \quad (2-10)$$

如果两个顶点之间有一条边, 那么对应的矩阵元素为 1, 否则为 0。对于自然邻居搜索算法得到的无向图, 因为自然邻居搜索算法通过对象互为邻居形成自然邻居集合, o_i 是 o_j 的自然邻居的同时意味着 o_j 是 o_i 的自然邻居, 而自己和自已不为邻居。因此自然邻居邻接矩阵是一个对称的方阵, 主对角线上的元素都是 0。

根据前文叙述得到自然邻居搜索算法1.

2.2.3 自然邻居熵

定义 2.2.12. 假设信息系统中有一个属性子集在 U 上通过自然邻居搜索得到了自然邻居邻接矩阵, 那么, 这个信息系统被称为自然邻居信息系统 (Natural Neighbor Information System, NaNIS), 表示为 $NaNIS = (U, CN, V, f)$, 其中 CN 为 NaNIS 的属性集。

定义 2.2.13. 对于 $P \subseteq CN$ 和 $\forall o_i \in U$, 给定 $NaN_P(o_i)$ 为属性子集 P 下由自然邻居搜索得到的 o_i 的自然邻居类, 定义 $NaNGS(P)$ 为属性子集 P 下的自然邻居粒 (Natural Neighbor Granularity Structure, NaNGS)。

$$NaN_P(o_i) = \{o_j : (o_i \in kNNS_P(o_j)) \wedge (o_j \in kNNS_P(o_i))\}. \quad (2-11)$$

$$NaNGS(P) = \{NaN_P(o_1), NaN_P(o_2), \dots, NaN_P(o_{|U|})\}, \quad (2-12)$$

算法 1: 自然邻居搜索算法**输入:** 数据集 $U = \{o_1, o_2, \dots, o_n\}$ **输出:** 自然邻居特征值 λ_P , 自然邻居邻接矩阵 $NNAM_P$

```

1  $k = 1, flag = 0, NNAM_P = [0]_{n \times n}$ 
2 创建数据集  $U$  的属性子集  $P$  下所对应的距离矩阵  $mat\_dis_P$ 
3 while  $flag == 0$  do
4   for  $\forall o_i \in U$  do
5      $knnSP(o_i) = kNNS_P(o_i) / (k - 1)NNS_P(o_i)$ ;
6     if  $o_i \in kNNS_P(knnSP(o_i)) \&\& NNAM_P[o_i, knnSP(o_i)] \neq 1$  then
7        $NNAM_P[o_i, knnSP(o_i)] = 1$ ;
8        $NNAM_P[knnSP(o_i), o_i] = 1$ ;
9     end
10  end
11  if  $\forall sum(NNAM_P[o_i]) \neq 0$  then
12     $flag = 1$ ;
13  end
14   $k = k + 1$ ;
15 end
16  $\lambda_P = k - 1$ ;
17 return  $\lambda_P, NNAM_P$ 

```

因此, 对于一个属性子集 $P = p_1 \cup p_2 \subseteq CN$, $\forall o_i \in U$, o_i 相对于属性子集 P 的自然邻居类被定义为:

$$NaN_P(o_i) = NaN_{p_1 \cup p_2}(o_i) = NaN_{p_1}(o_i) \cap NaN_{p_2}(o_i). \quad (2-13)$$

$NaN_P(o_i)$ 可以看作是一种特殊的邻域类, 它通过自适应判断是否互为邻居的方式被确定。其在 U 上的邻域关系可以用上述定义的自然邻居邻接矩阵表示, 易知其满足对称性 $NNAM_P[o_i, o_j] = NNAM_P[o_j, o_i]$ 。同时, U 上所有对象的自然邻居类的集合构成了自然邻居粒 $NaNGS$, 它形成了 U 的邻域覆盖, 即 $NaNGS$ 这个自然邻居粒能把 U 中所有的对象都包含, 它可以被看作是一个满足互为邻居关系的自然邻居知识集群, 其中每个邻域覆盖被称为一个自然邻居类。由上文定义 2.2.5 所述, 邻域熵能度量不确定性。因此, 将邻域熵的概念扩展到 $NaNIS$ 中, 就可以通过计算每个对象自然邻居类的平均不确定性无参地衡量邻域粗糙集的不确定性。于是, 我们在 $NaNIS$ 中提出自然邻居熵。

定义 2.2.14. 给定 $NaNIS = (U, CN, V, f)$, 对于 $P \subseteq CN$ 和 $\forall o_i \in U$, 关于属性子集

P 的自然邻居熵 (Natural Neighbor Entropy, NaNE) 定义为:

$$NaNE(P) = -\frac{1}{|U|} \sum_{i=1}^n \log_2 \frac{|NaN_P(o_i)|}{|U|}. \quad (2-14)$$

自然邻居熵将自然邻居的思想融入了邻域熵, 通过自然邻居搜索达到自然邻居稳定状态来确定自然邻居粒, 得到一种特殊的邻域类 $NaN_P(o_i)$, 即自然邻居类。这种方法不需要人为设定邻域半径, 很好地避免了参数依赖。若自然邻居粒 $NaN_{GS} = U \times U$, 则自然邻居熵的值为 0; 若 $NaN_{GS} = U$, 则自然邻居熵的值为 $\log_2 n$ 。因此, $0 \leq NaNE(P) \leq \log_2 n$ 。

2.2.4 自然邻居比率熵

在自然邻居熵的基础上进一步提出基于自然邻居比率熵的新概念, 用于表征论域 U 中每个对象的不确定性。

定义 2.2.15. 对于 $\forall o_i \in U$, 自然邻居比率熵 (Natural Neighbor Ratio Entropy, NaNRE) 定义为:

$$NaNRE_P(o_i) = \begin{cases} \frac{NaN_{E_{o_i}}(P)}{NaN_E(P)}, & 0 \leq \frac{NaN_{E_{o_i}}(P)}{NaN_E(P)} \leq 1 \\ 1, & otherwise \end{cases} \quad (2-15)$$

其中 $NaN_{E_{o_i}}(P) = -\frac{1}{|U \setminus \{o_i\}|} \sum_{r=1}^{|U|-1} \log_2 \frac{|NaN_P(o_r)|}{|U \setminus \{o_i\}|}$ 表示条件自然邻居熵, 即论域 U 去除对象 o_i 后的自然邻居熵。

自然邻居比率熵可以度量 o_i 的不确定性程度。若删去对象 o_i 后, 自然邻居熵下降, 则 o_i 的不确定性较高; 若删去对象 o_i 后, 自然邻居熵变化较小甚至有所上升, 则 o_i 的不确定性较低。具体来说 o_i 对应的 $NaNRE_P(o_i)$ 越低, o_i 的不确定性越高, o_i 越有可能是异常点。因此, 基于 $NaN_{E_{o_i}}(P)$ 及其语义, 可以使用 $NaNRE_P(o_i)$ 来指示对象的异常。

2.2.5 相关不确定性度量

定义 2.2.16. 联合熵是指在给定两个属性子集下共同的不确定性, 它可以用来衡量属性之间的相关性或依赖性。因为对比单个属性子集下的熵, 两个属性子集之间的相关性越强, 自然邻居邻域联合熵的值越接近自然邻居熵的值。对于 $P, Q \subseteq CN, \forall o_i \in U$, 给定对应属性子集下自然邻居粒 $NaN_{GS}(P)$ 和 $NaN_{GS}(Q)$, 则关于自然邻居关系 $NaN_{PUQ}(o_i)$ 的自然邻居联合熵定义为:

$$NaNE(P, Q) = -\frac{1}{|U|} \sum_{i=1}^{|U|} \log_2 \frac{|NaN_P(o_i) \cap NaN_Q(o_i)|}{|U|}. \quad (2-16)$$

定义 2.2.17. 条件熵是指在给定一个属性子集的条件下, 另一个属性子集的平均不确定性, 它可以用来衡量属性之间的信息量或冗余度。对于 $P, Q \subseteq CN$, $\forall o_i \in U$, 给定对应属性子集下自然邻居粒 $NaN_{GS}(P)$ 和 $NaN_{GS}(Q)$, 则关于自然邻居关系 $NaN_{P \cup Q}(o_i)$ 的自然邻居条件熵定义为:

$$cNaN_{NE}(Q | P) = -\frac{1}{|U|} \sum_{i=1}^{|U|} \log_2 \frac{|NaN_P(o_i) \cap NaN_Q(o_i)|}{|NaN_P(o_i)|}. \quad (2-17)$$

性质 1 如果 $P, Q \subseteq CN$, $\forall o_i \in U$, 则 $cNaN_{NE}(Q | P) = NaN_{NE}(P, Q) - NaN_{NE}(P)$ 。

定义 2.2.18. 互信息是指两个属性子集之间的信息流量或相互依赖程度, 它可以用来衡量属性之间的相关性或冗余度。对于 $P, Q \subseteq CN$, $\forall o_i \in U$, 给定对应属性子集下自然邻居粒 $NaN_{GS}(P)$ 和 $NaN_{GS}(Q)$, 则关于自然邻居关系 $NaN_{P \cup Q}(o_i)$ 的自然邻居互信息定义为:

$$NaN_{MI}(P; Q) = NaN_{NE}(P) + NaN_{NE}(Q) - NaN_{NE}(P, Q), \quad (2-18)$$

其中, $NaN_{NE}(P)$ 和 $NaN_{NE}(Q)$ 是属性子集 P 和 Q 的自然邻居熵, $NaN_{NE}(P, Q)$ 是属性子集 P 和 Q 的自然邻居联合熵。自然邻居互信息也可以表示为:

$$NaN_{MI}(P; Q) = -\frac{1}{|U|} \sum_{i=1}^{|U|} \log_2 \frac{|NaN_P(o_i)| \cdot |NaN_Q(o_i)|}{|U| \cdot |NaN_P(o_i) \cap NaN_Q(o_i)|}. \quad (2-19)$$

2.3 异常检测模型

为构建基于自然邻居熵的异常因子, 本章在前一小节提出基于自然邻居比率熵的新概念, 用于表征论域 U 中每个对象的不确定性。

此外, 权重函数对异常因子和检测结果具有正向影响, 但权重函数通常是经验函数。为获得更准确的异常检测结果, 基于大量实验, 定义具体权重如下:

定义 2.3.1. 对于 $o_i \in U$ 的权重函数 $W_P(o_i)$ 定义为:

$$W_P(o_i) = \sqrt{\frac{|NaN_P(o_i)|}{|U|}}. \quad (2-20)$$

上述权重函数设定的核心思想是: 异常检测方法通常关注少数类, 因为少数类中的对象更可能是异常值, 因此少数类中的对象应被赋予较低的权重。在公式 2.3.1 中, 若对象 o_i 的邻域中包含的对象较少, 则 o_i 在论域 U 中所占比例较小, 属于少数类, 对应较低的权重。此外, 显然 $W_B(o_i) \in (0, 1]$ 。

由上述定义 2.2.15 和 2.3.1 可知, 邻域关系不同, 得到的熵和权重也不一样。每个 $P \subseteq CN$ 都能确定一个自然邻居粒 NaN_{GS} , 它也可以被视为自然邻居信息系统中的自然邻

居知识群。因此, 存在 $2^{|CN|}$ 个不同的属性子集, 也就可以得到 $2^{|CN|}$ 个自然邻居粒用于构建知识库。显然, 这样计算每个对象的 $RE_B(o_i)$ 和 $W_B(o_i)$ 能获得更丰富的数据信息, 但这种方式在计算上不可行, 复杂度随 $|CN|$ 呈指数增长。需要构建属性序列和属性子集序列来计算 $RE_B(o_i)$ 和 $W_B(o_i)$ 。

定义 2.3.2. 属性序列 AS 定义为:

$$AS = \langle c'_1, c'_2, \dots, c'_m \rangle \quad (2-21)$$

其中, $NaNE(\{c'_k\}) \leq NaNE(\{c'_{k+1}\})$ 。

从单属性集 c'_1 或 c'_m 开始, 每次以正向方式从 AS 中添加属性, 添加完所有属性为止, 可得到属性子集前向序列。

定义 2.3.3. 属性子集前向序列 AFS 和反向序列 ARS 可定义为:

$$AFS = \langle C_1, C_2, \dots, C_m \rangle \quad (2-22)$$

$$ARS = \langle C'_1, C'_2, \dots, C'_m \rangle \quad (2-23)$$

其中, $C_k \subseteq C$, $C_m = C$, $C_1 = \{c'_1\}$, $C_{k+1} = C_k \cup \{c'_{k+1}\}$; $C'_k \subseteq C$, $C'_1 = \{c'_m\}$, $C'_m = C$, $C'_{k+1} = C'_k \cup \{c'_{m-k}\}$ 。

由上述定义2.3.2和2.3.3可知, 每种属性序列中的每个属性集都能确定一个自然邻居粒, 进而得到每个自然邻居粒下对应的自然邻居熵。因此, 基于这两种属性序列 AS、AFS、ARS, 构建三种自然邻居熵序列。

定义 2.3.4. 三种自然邻居熵序列分别定义为:

$$MNES = \langle NaNE\{c'_1\}, \dots, NaNE\{c'_m\} \rangle \quad (2-24)$$

$$FMNES = \langle NaNE\{C_1\}, \dots, NaNE\{C_m\} \rangle \quad (2-25)$$

$$RMNES = \langle NaNE\{C'_1\}, \dots, NaNE\{C'_m\} \rangle \quad (2-26)$$

基于上述定义, 构建三种自然邻居比率熵矩阵。

定义 2.3.5. 三种自然邻居比率熵矩阵分别定义为:

$$ERM_{AS} = \left(NaNRE_{\{c'_k\}}(o_i) \right)_{n \times m} \quad (2-27)$$

$$ERM_{AFS} = \left(NaNRE_{\{C_k\}}(o_i) \right)_{n \times m} \quad (2-28)$$

$$ERM_{ARS} = \left(NaNRE_{\{C'_k\}}(o_i) \right)_{n \times m} \quad (2-29)$$

类似地,可以得到三种权重函数矩阵。

定义 2.3.6. 三种权重函数矩阵分别定义为:

$$WM_{AS} = \left(W_{\{c'_k\}}(o_i) \right)_{n \times m} \quad (2-30)$$

$$WM_{AFS} = \left(W_{\{C_k\}}(o_i) \right)_{n \times m} \quad (2-31)$$

$$WM_{ARS} = \left(W_{\{C'_k\}}(o_i) \right)_{n \times m} \quad (2-32)$$

定义 2.3.7. 平均自然邻居比率熵矩阵和平均权重矩阵分别计算为:

$$AERM = \frac{1}{3}(ERM_{AS} + ERM_{AFS} + ERM_{ARS}) \quad (2-33)$$

$$AWM = \frac{1}{3}(WM_{AS} + WM_{AFS} + WM_{ARS}) \quad (2-34)$$

平均自然邻居比率熵矩阵的构建融合了两种属性序列的信息,为构建基于自然邻居比率熵的异常因子奠定基础。

在现实生活中,对于许多复杂数据场景,为每个对象赋予一定的异常程度更具实际意义。因此, Breunig 等人^[28]提出了一种基于密度的局部异常识别方法。本文基于平均自然邻居比率熵矩阵和平均权重函数矩阵,构建自然邻居比率熵异常因子 (NaNREAF) 来表征每个对象的异常程度。

NaNREAD 模型的框架如图所示。该图概述了基于自然邻居比率熵的异常检测的过程。其中左上角为输入模型的无决策信息系统 NIS , 在该原始数据输入中, $c_1, c_2, \dots, c_n$ 表示信息系统中的不同属性, 以不同颜色表示; $o_1, o_2, \dots, o_n$ 表示信息系统中的不同对象, 以不同渐变表示。模型首先通过自然邻居搜索 (Natural Neighborhood Search, NNS) 构建自然邻接矩阵 $NNAM$, 这些矩阵是对称阵, 每个矩阵唯一对应一种属性, 在图中也用颜色指出。基于自然邻接矩阵, 我们随后构建自然邻居粒 $NaNGS$, 计算自然邻居熵 $NaNE$ 。然后构建属性序列 AS, AFS 和 ARS 。随后计算三种自然邻居比率熵矩阵 ERM_S, ERM_{FS} 和 ERM_{RS} , 构建平均自然邻居比率熵矩阵 $AERM$ 。与此同时, 基于自然邻居邻接矩阵可以构建三个属性序列的权重矩阵 WM_S, WM_{FS} 和 WM_{RS} , 随后计算平均权重矩阵 AWM 。最后模型基于平均权重矩阵和平均自然邻居比率熵矩阵计算自然邻居比率熵异常因子 $NaNREAF$ 并输出。

定义 2.3.8. 对于任意 $o_i \in U, o_i$ 的自然邻居比率熵异常因子 $NaNREAF(o_i)$ 定义为:

$$NaNREAF(o_i) = 1 - \frac{\sum_{k=1}^m AERM(i, k)AWM(i, k)}{|CN|} \quad (2-35)$$

其中 $AERM(i, k)$ 和 $AWM(i, k)$ 分别表示平均比率熵矩阵和平均权重函数矩阵中第 i 行第 k 列的元素。




图 2.1 NaNREAD 模型的框架图

Figure 2.1 Overall framework of NaNREAD

定义 2.3.9. 设 μ 为判断阈值, 对于任意 $o_i \in U$, 若 $NaNREAF(o_i) > \mu$, 则称 o_i 为基于自然邻居比率熵的异常值。

为进一步说明上述思想, NaNREAD 的框架图如2.1所示。该图展示了基于自然邻居比率熵的异常检测过程。其中最左侧为信息系统的原始数据输入, $o_1, o_2, \dots, o_n$ 表示样本集 U 中的不同样本, $c_1, c_2, \dots, c_n$ 表示属性集 C 中的不同属性。首先通过自然邻居搜索过程达到自然邻居稳定状态, 得到自然邻居特征值 λ 和自然邻居邻接矩阵 (NNAM)。然后在自然邻居信息系统中构建自然邻居粒 (NaNGS), 得到自然邻居熵 (NaNE)。接着计算两种属性序列的自然邻居比率熵 (NaNRE)、权重函数, 得到平均自然邻居比率熵矩阵 (AERM) 和平均权重函数矩阵 (AWM), 加权融合多属性下的 AERM 和 AWM 值得到异常因子 (NaNCEAF)。最终将异常因子与预设阈值 μ 进行比较, 从而判定异常值, 实现异常检测。

2.4 异常检测算法

本节提出并设计相应的 NaNREAD 算法:

在 NaNREAD 算法中, 步骤 1-6 和步骤 9-14 均对 m 个属性进行处理, 其中自然邻居邻接矩阵搜索算法复杂度为 $O(n^2)$, 每个属性执行一次, 总体均为 $O(mn^2)$; 步骤 15-21 中对每个样本 i 的每个属性 k 分别计算自然邻居比率熵、权重函数, 总体为 $O(mn)$; 步骤 20 中对每个样本计算一次异常因子和分数, 总体为 $O(n)$ 。因此, 算法的整体时间复杂度为 $O(mn^2)$, 空间复杂度同为 $O(mn^2)$ 。

2.5 示例说明

表 2.1 初始和标准化自然邻居信息系统

Table 2.1 Initial and Standardized Natural Neighbor Information Systems

U	c_1	c_2	c_3	U	c_1	c_2	c_3
o_1	3	8	10	o_1	1	$\frac{8}{10}$	1
o_2	1	0	5	o_2	0	0	0
o_3	3	7	10	o_3	1	$\frac{7}{10}$	1
o_4	3	10	7	o_4	1	1	$\frac{2}{5}$
o_5	2	10	8	o_5	$\frac{1}{2}$	1	$\frac{3}{5}$

例 2.5.1. 设 $NaNIS = (U, N, V, f)$ 为表 2.1 左栏所列的自然邻居信息系统, 其中 $U = \{o_1, o_2, o_3, o_4, o_5\}$, $C = \{c_1, c_2, c_3\}$ 。数据预处理之后所得数据如表 2.1 的右边。

具体步骤如下:

(1) 使用算法 1 遍历 C 中的元素, 获得三个元素的自然邻居邻接矩阵:

$$NNAM_{c_1} = \begin{bmatrix} 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$NNAM_{c_2} = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 & 0 \end{bmatrix}$$

算法 2: NaNREAD 算法**输入:** $NaNIS = (U, CN, V, f)$ **输出:** NaNREAF

```

1 for  $k \leftarrow 1$  to  $m$  do
2   通过自然邻居搜索算法计算属性  $c_k$  下的自然邻居特征值  $\lambda_{c_k}$ 
3   通过自然邻居搜索算法计算属性  $c_k$  下的自然邻居邻接矩阵  $NNAM_{c_k}$ 
4   根据公式2.2.13计算属性  $c_k$  下的自然邻居粒  $NaNGS(\{c_k\})$ 
5   根据公式2.2.14计算属性  $c_k$  下的自然邻居熵  $NaNE(\{c_k\})$ 
6 end
7 根据自然邻居熵确定属性序列  $AS = \langle c'_1, c'_2, \dots, c'_m \rangle$ 
8 构建前向属性子集序列  $AFS = \langle C_1, C_2, \dots, C_m \rangle$ 
9 和后向属性子集序列  $ARS = \langle C'_1, C'_2, \dots, C'_m \rangle$ 
10 for  $k \leftarrow 1$  to  $m$  do
11   通过自然邻居搜索算法分别计算属性集  $C_k$  和  $C'_k$  下的自然邻居特征值  $\lambda_{C_k}$  和  $\lambda_{C'_k}$ 
12   通过自然邻居搜索算法分别计算属性集  $C_k$  和  $C'_k$  下的自然邻居邻接矩阵  $NNAM_{C_k}$  和  $NNAM_{C'_k}$ 
13   根据定义2.2.13计算属性集  $C_k$  和  $C'_k$  下的自然邻居粒  $NaNGS(\{C_k\})$  和  $NaNGS(\{C'_k\})$ 
14   根据公式2.2.14计算属性集  $C_k$  和  $C'_k$  下的自然邻居熵  $NaNE(\{C_k\})$  和  $NaNE(\{C'_k\})$ 
15 end
16 for  $i = 1$  to  $n$  do
17   for  $k \leftarrow 1$  to  $m$  do
18     根据公式2.2.15计算  $NaNRE_{\{c'_k\}}(o_i)$ 、 $NaNRE_{\{C_k\}}(o_i)$  和  $NaNRE_{\{C'_k\}}(o_i)$ 
19     根据公式2.3.1计算  $W_{\{c'_k\}}(o_i)$ 、 $W_{\{C_k\}}(o_i)$ 
20     和  $W_{\{C'_k\}}(o_i)$ 
21   end
22   根据公式2.3.7和2.3.8计算自然邻居比率熵异常因子  $NaNREAF(o_i)$ 
23 end
24 return  $NaNREAF$ 

```

$$NNAM_{c_3} \begin{bmatrix} 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 \end{bmatrix}$$

由 $NNAM$, 根据公式 2.2.14 有每个属性的自然邻居熵:

$$NaNE(c_1) = -\frac{1}{|U|} \sum_{i=1}^n \log_2 \frac{|NaN_P(o_i)|}{|U|} = -\frac{1}{5} \left(\log_2 \left(\frac{2}{5} \times \frac{1}{5} \times \frac{2}{5} \times \frac{2}{5} \times \frac{1}{5} \right) \right) = 1.7219$$

$$NaNE(c_2) = 0.3219$$

$$NaNE(c_3) = 1.4049$$

于是根据 2.3.2 有 $AS = \langle c_2, c_3, c_1 \rangle$, 相应地, 根据 2.3.3 有 $AFS = \langle \{c_2\}, \{c_2, c_3\}, \{c_2, c_3, c_1\} \rangle$,
 $ARS = \langle \{c_1\}, \{c_1, c_3\}, \{c_1, c_3, c_2\} \rangle$

(2) 遍历 AS, AFS, ARS 中的属性子集元素, 计算每个属性集下的自然邻居熵。

以 $\{c_2, c_3\}$ 为例:

由公式 2-1 获得该属性子集下的距离矩阵:

$$dist_{\{c_2, c_3\}} = \begin{bmatrix} 0 & 1.2806 & 0.1 & 0.6325 & 0.4472 \\ 1.2806 & 0 & 1.2207 & 1.0770 & 1.1662 \\ 0.1 & 1.2207 & 0 & 0.6708 & 0.5 \\ 0.6325 & 1.0770 & 0.6708 & 0 & 0.2 \\ 0.4472 & 1.1662 & 0.5 & 0.2 & 0 \end{bmatrix}$$

根据公式 2.2.11 有该属性子集下的自然邻居邻接矩阵:

$$NNAM_{\{c_2, c_3\}} = \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 & 0 \end{bmatrix}$$

$$\lambda_{\{c_2, c_3\}} = 4$$

根据公式 2.2.13 有:

$$\begin{aligned} NaNGS(\{c_2, c_3\}) = & \{ \{o_2, o_3, o_4, o_5\}, \\ & \{o_1, o_3, o_4, o_5\}, \\ & \{o_1, o_2, o_4, o_5\}, \\ & \{o_1, o_2, o_3, o_5\}, \\ & \{o_1, o_2, o_3, o_4\} \} \end{aligned}$$

根据公式 2.2.14, 有:

$$NaNE(\{c_2, c_3\}) = -\frac{1}{|U|} \sum_{i=1}^n \log_2 \frac{|NaN_P(o_i)|}{|U|} = -\frac{1}{5} \left(\log_2 \left(\left(\frac{4}{5} \right)^5 \right) \right) = 0.3219$$

由公式2-1获得去除点 o_1 后, 该属性子集下的距离矩阵:

$$dist_{\{c_2, c_3\}}(o_1) = \begin{bmatrix} 0 & 1.2207 & 1.0770 & 1.1662 \\ 1.2207 & 0 & 0.6708 & 0.5 \\ 1.0770 & 0.6708 & 0 & 0.2 \\ 1.1662 & 0.5 & 0.2 & 0 \end{bmatrix}$$

由公式2.2.11有:

$$NNAM_{\{c_2, c_3\}}(o_1) = \begin{bmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

$$\lambda\{c_2, c_3\} = 3$$

根据公式2.2.14, 有:

$$NaNE(\{c_2, c_3\}) = -\frac{1}{|U|} \sum_{i=1}^n \log_2 \frac{|NaN_P(o_i)|}{|U|} = -\frac{1}{5} \left(\log_2 \left(\left(\frac{3}{4} \right)^4 \right) \right) = 0.4150$$

根据公式2.2.15, 有:

$$NaNRE_{\{c_2, c_3\}}(o_1) = 1, \quad \left(\frac{NaN_{E_{o_1}}(\{c_2, c_3\})}{NaN_E(\{c_2, c_3\})} = 1.2892 > 1 \right)$$

同理, 其他点的自然邻居比率熵为:

$$NaNRE_{\{c_2, c_3\}}(o_2) = 1, \quad \left(\frac{NaN_{E_{o_2}}(\{c_2, c_3\})}{NaN_E(\{c_2, c_3\})} = 6.2125 > 1 \right)$$

$$NaNRE_{\{c_2, c_3\}}(o_3) = 1, \quad \left(\frac{NaN_{E_{o_3}}(\{c_2, c_3\})}{NaN_E(\{c_2, c_3\})} = 1.2892 > 1 \right)$$

$$NaNRE_{\{c_2, c_3\}}(o_4) = 1, \quad \left(\frac{NaN_{E_{o_4}}(\{c_2, c_3\})}{NaN_E(\{c_2, c_3\})} = 1.2892 > 1 \right)$$

$$NaNRE_{\{c_2, c_3\}}(o_5) = 1, \quad \left(\frac{NaNRE_{o_5}(\{c_2, c_3\})}{NaNRE(\{c_2, c_3\})} = 1.2892 > 1 \right)$$

同理，其他属性的自然邻居比率熵为：

$$NaNRE_{\{c_1\}}(o_1) = 1, \quad NaNRE_{\{c_1\}}(o_2) = 0.2410, \quad NaNRE_{\{c_1\}}(o_3) = 1,$$

$$NaNRE_{\{c_1\}}(o_4) = 1, \quad NaNRE_{\{c_1\}}(o_5) = 0.2410,$$

$$NaNRE_{\{c_2\}}(o_1) = 1, \quad NaNRE_{\{c_2\}}(o_2) = 1, \quad NaNRE_{\{c_2\}}(o_3) = 1,$$

$$NaNRE_{\{c_2\}}(o_4) = 1, \quad NaNRE_{\{c_2\}}(o_5) = 1,$$

$$NaNRE_{\{c_3\}}(o_1) = 1, \quad NaNRE_{\{c_3\}}(o_2) = 1, \quad NaNRE_{\{c_3\}}(o_3) = 1,$$

$$NaNRE_{\{c_3\}}(o_4) = 0.2954, \quad NaNRE_{\{c_3\}}(o_5) = 1,$$

$$NaNRE_{\{c_1, c_3\}}(o_1) = 1, \quad NaNRE_{\{c_1, c_3\}}(o_2) = 1, \quad NaNRE_{\{c_1, c_3\}}(o_3) = 1,$$

$$NaNRE_{\{c_1, c_3\}}(o_4) = 1, \quad NaNRE_{\{c_1, c_3\}}(o_5) = 1,$$

$$NaNRE_{\{c_1, c_2, c_3\}}(o_1) = 1, \quad NaNRE_{\{c_1, c_2, c_3\}}(o_2) = 1,$$

$$NaNRE_{\{c_1, c_2, c_3\}}(o_3) = 1, \quad NaNRE_{\{c_1, c_2, c_3\}}(o_4) = 1,$$

$$NaNRE_{\{c_1, c_2, c_3\}}(o_5) = 1$$

故而：

$$NaNRE_{AS} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 0.2410 \\ 1 & 1 & 1 \\ 1 & 0.2954 & 1 \\ 1 & 1 & 0.2410 \end{bmatrix}, \quad NaNRE_{AFS} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix},$$

$$NaNRE_{ARS} = \begin{bmatrix} 1 & 1 & 1 \\ 0.2410 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \\ 0.2410 & 1 & 1 \end{bmatrix}$$

(3) 根据公式2.3.1以及上两步计算的自然邻居粒，权重矩阵很容易获得：

例：

$$W_{c_1}(o_1) = \sqrt{\frac{|NaN_{c_1}(o_1)|}{|U|}} = \sqrt{\frac{2}{5}} = 0.6325$$

同理可计算：

$$\begin{aligned}
 WM_{AS} &= \begin{bmatrix} 0.8944 & 0.6325 & 0.6325 \\ 0.8944 & 0.4472 & 0.4472 \\ 0.8944 & 0.6325 & 0.6325 \\ 0.8944 & 0.6325 & 0.6325 \\ 0.8944 & 0.7746 & 0.4472 \end{bmatrix} \\
 WM_{AFS} &= \begin{bmatrix} 0.8944 & 0.8944 & 0.8944 \\ 0.8944 & 0.8944 & 0.8944 \\ 0.8944 & 0.8944 & 0.8944 \\ 0.8944 & 0.8944 & 0.8944 \\ 0.8944 & 0.8944 & 0.8944 \end{bmatrix} \\
 WM_{ARS} &= \begin{bmatrix} 0.6325 & 0.8944 & 0.8944 \\ 0.4472 & 0.8944 & 0.8944 \\ 0.6325 & 0.8944 & 0.8944 \\ 0.6325 & 0.8944 & 0.8944 \\ 0.4472 & 0.8944 & 0.8944 \end{bmatrix}
 \end{aligned}$$

(4) 根据公式2.3.7, 有平均自然邻居比率熵矩阵 AERM 和平均权重矩阵 AWM:

$$\begin{aligned}
 AERM &= \frac{1}{3}(ERM_{AS} + ERM_{AFS} + ERM_{ARS}) = \begin{bmatrix} 1 & 1 & 1 \\ 0.7470 & 1 & 0.7470 \\ 1 & 1 & 1 \\ 1 & 0.7651 & 1 \\ 0.7470 & 1 & 0.7470 \end{bmatrix} \\
 AWM &= \frac{1}{3}(WM_{AS} + WM_{AFS} + WM_{ARS}) = \begin{bmatrix} 0.8071 & 0.8071 & 0.8071 \\ 0.7454 & 0.7454 & 0.7454 \\ 0.8071 & 0.8071 & 0.8071 \\ 0.8071 & 0.8071 & 0.8071 \\ 0.7454 & 0.8545 & 0.7454 \end{bmatrix}
 \end{aligned}$$

(5) 最后, 根据公式2.3.8, 计算出每个点的异常分数:

例:

$$\begin{aligned}
 \text{NaNREAF}(o_1) &= 1 - \frac{\sum_{k=1}^m \text{AERM}(1, k) \text{AWM}(1, k)}{|CN|} \\
 &= 1 - \frac{0.8071 + 0.8071 + 0.8071}{3} \\
 &= 0.1929
 \end{aligned}$$

$$\text{NaNREAF} = \begin{bmatrix} 0.1929 & 0.3804 & 0.1929 & 0.2561 & 0.3440 \end{bmatrix}$$

o_2 和 o_5 因为异常分数高于其他对象，被算法判断为异常点。

2.6 实验分析

2.6.1 实验准备

为验证 NaNREAD 算法的有效性，从公开的 UCI 数据库^{1,2}中选取了 15 个数据集进行实验。针对上述选定数据集，本章将 NaNREAD 算法的性能与以下 10 种算法进行比较：

为确保结果与实际场景高度契合，每种比较方法均采用了其原始论文中描述的实验设置。

- (1) 基于序列的异常检测算法 (SEQ)^[29]: 该方法在粗糙集理论框架下，通过分析对象随属性子集缩减时其等价类的变化情况，提出了一种异常检测算法。
- (2) 基于信息熵的异常检测算法 (IE)^[30]: 该方法将信息熵模型引入粗糙集理论，通过计算对象的相对熵，提出了一种异常检测算法。
- (3) 基于信息论的异常检测算法 (ITB)^[31]: 该方法结合信息熵与全相关提出了“全熵” (Holoentropy) 概念，提出一种针对大规模分类数据的异常检测算法。
- (4) 基于加权密度的异常检测算法 (WDOD)^[32]: 该方法综合考虑了分类数据在各属性上的局部密度和信息熵带来的不确定性，提出了一种异常检测算法。
- (5) 基于粒计算与粗糙集的异常检测算法 (ODGrCR)^[33]: 该方法结合粒计算与粗糙集理论，通过计算信息粒的近似精度，提出了一种全局异常检测算法。
- (6) 基于近似结构评分的异常检测算法 (ApproE)^[34]: 该方法从有意义的结构评分视角出发，提出了一种针对高维空间数据的异常检测算法。
- (7) 基于方差结构评分的异常检测算法 (VarE)^[34]: 该方法将全局数据结构纳入考量，通过加权的角度方差提出了一种异常检测算法。
- (8) 基于局部-全局邻域信息的异常检测算法 (ILGNI)^[35]: 该方法通过构建不完整局部和全局邻域信息网络，提出了一种有效处理不完整混合数据的图异常检测算法。

¹<https://github.com/from-china-to/Outlier-detection>

²<https://github.com/Belloney/Outlier-detection>

- (9) 基于多尺度模糊信息融合异常检测算法 (MFIOD)^[36]: 该方法结合模糊粗糙集理论, 通过融合多尺度模糊颗粒信息提出了一种无监督的多尺度异常检测算法。
- (10) 基于变分自编码器的异常检测算法 (VAE)^[37]: 该方法提出基于变分自编码器的深度异常检测方案, 采用数据重构过程中的重建误差作为异常评分指标。

数据预处理和数据集的描述见表2.2, 相关数据集可以在 Github 主页下载。

表 2.2 数据集介绍

Table 2.2 Description of datasets

序号	数据集名称	缩写	属性数	对象数	异常点数	领域
1	Annealing_variant1	Anneal	38	798	42	钢材退火 (制造)
2	Bands_band_6_variant1	Bands	39	318	6	印刷 (制造)
3	Breast_cancer_variant1	Breast	9	286	85	乳腺癌 (医学)
4	Cardiotocography_2and3_33_variant1	Cardio	21	1688	33	胎儿体征 (医学)
5	Chess_nowin_34_variant1	Chess	36	1703	34	国际象棋 (游戏)
6	Diabetes_tested_positive_26_variant1	Diabetes	8	526	26	糖尿病 (医学)
7	Glass	Glass	9	214	9	环境分析 (环保)
8	Ionosphere_b_24_variant1	Iono	34	249	24	雷达信号 (电信)
9	Letter	Letter	32	1600	100	字母 (文档)
10	Monks_0_4_variant1	Monk	6	232	4	归纳算法 (数学)
11	Pima_TRUE_55_variant1	Pima	9	555	55	糖尿病 (医学)
12	Tic_tac_toe_negative_12_variant1	Tic12	9	638	12	一字棋 (游戏)
13	Tic_tac_toe_negative_26_variant1	Tic26	9	652	26	一字棋 (游戏)
14	Vowels	Vowels	12	1456	50	语音信息 (电信)
15	Zoo_variant1	Zoo	16	101	17	动物 (生物)

在实验过程中, 针对不同异常检测算法的特性进行了相应的参数配置与数据处理。首先, 由于 SEQ、IE、ITB、WDOD 和 ODGrCR 算法在处理连续型属性时受到限制, 实验中统一采用模糊 C 均值 (Fuzzy C-Means, FCM) 方法对这五个算法的数据集进行离散化预处理。ApproE 和 VarE 算法的正则化参数 λ 被设置为 0.1。ILGNI 算法中, 逻辑斯蒂函数的参数 a 和 b 被设置为 1 和 100。MFIOD 算法的属性尺度参数 λ 在 $[0.05, 1]$ 中以步长 0.1 迭代寻找最优参数。VAE 算法的全局步长参数是 s 从 $\{0.01, 0.02, 0.1\}$ 选取最优。ITB 算法仅需异常点数量 o 而无需其他参数。SEQ、IE、WDOD 和 ODFrCR 算法依赖 “Top ratio” 参数, 实验中依据数据集异常点比例配置该参数。

在实际应用的很多场景中, 正常的数据量远远超过了异常的数据量, 导致数据分布呈现出极度的不平衡特征。在这种情况下, 使用常见的准确率等指标来评价异常检测算法的性能是不合适的, 因为这些指标不能客观地反映算法对异常数据的识别能力和效果。

因此, 本章采用 ROC 曲线和 AUC 指标来对算法性能进行综合评估。

2.6.2 实验结果分析

11 种检测算法的 ROC 曲线见图2.2，其中黑色曲线表示本章提出的 NaNREAD 算法。所有对比算法的 ROC 曲线均表现为单调递增，如图2.2所示。正如前文所述，检测算法的 ROC 曲线越接近图像左上角，性能越优。

根据图2.2，提出的 NaNREAD 算法在大部分数据集上的 ROC 曲线明显最接近第一象限的左上角，如 Bands、Cardio、Iono、Letter 和 Monk。其中，NaNREAD 算法在 Iono 和 Monk 上的 ROC 曲线与坐标完全重合，表明其表现出足够的性能。此外，在其他一些数据集上，如 Anneal、Breast、Chess、Diabetes 和 Vowels，NaNREAD 算法较为接近第一象限的左上角，曲线下的面积较大，性能与其他算法相当或稍弱。因此，我们可以得出结论，NaNREAD 算法在大多数数据集上表现出最好的性能。后面，本章进一步分析了 10 种检测算法关于 AUC 指数的比较结果，如表2.3所示。

表 2.3 AUC 实验评估表

Table 2.3 Experimental evaluation of AUC

数据集	NaNREAD	SEQ	IE	ITB	WDOD	ODGrCR	ApproE	VarE	ILGNI	MFIOD	VAE
Anneal	0.7858	0.7820	0.7369	0.7657	0.7476	0.7343	0.7526	0.6195	0.6864	0.7430	0.7522
Bands	0.9557	0.7094	0.7468	0.7062	0.7345	0.8237	0.7425	0.7025	0.8745	0.5454	0.9167
Breast	0.6832	0.6702	0.6450	0.6699	0.6786	0.6521	0.6416	0.6369	0.6587	0.6391	0.6007
Cardio	0.8522	0.5604	0.5085	0.6729	0.6407	0.5811	0.7954	0.7797	0.8111	0.6966	0.8431
Chess	0.9662	0.9597	0.9253	0.9642	0.9654	0.9662	0.8880	0.8920	0.9346	0.9565	0.9432
Diabetes	0.9700	0.9568	0.9298	0.9528	0.9514	0.9578	0.9694	0.9652	0.9055	0.9898	0.9215
Glass	0.6618	0.6938	0.6924	0.6629	0.6791	0.6778	0.6287	0.5382	0.4818	0.7252	0.5344
Iono	0.9998	0.9678	0.9581	0.9885	0.9854	0.9759	0.5165	0.4559	0.9981	0.9996	0.9994
Letter	0.7812	0.5315	0.5877	0.5163	0.5294	0.5382	0.5938	0.5292	0.5816	0.5740	0.5252
Monk	1.0000	0.9868	1.0000	1.0000	0.9868	1.0000	0.7719	0.7270	1.0000	0.9868	0.9386
Pima	0.9314	0.9289	0.8919	0.9389	0.9190	0.9382	0.9200	0.9040	0.9007	0.9755	0.8615
Tic12	0.9609	0.9000	0.8319	0.9032	0.9076	0.9121	0.7983	0.7330	0.8126	0.8244	0.8126
Tic26	0.8821	0.7844	0.8227	0.7571	0.7755	0.7756	0.6855	0.6433	0.7892	0.7592	0.7761
Vowels	0.9343	0.5886	0.5822	0.5799	0.5896	0.5519	0.9526	0.8781	0.6092	0.6389	0.6170
Zoo	0.6520	0.5357	0.6471	0.5658	0.5413	0.5707	0.3235	0.6828	0.5889	0.6723	0.6562
平均值	0.8678	0.7704	0.7671	0.7763	0.7755	0.7771	0.7320	0.7125	0.7755	0.7818	0.7799
排名第一的个数	10	0	1	1	0	1	1	1	1	3	0

表2.3展示了 AUC 的实验结果，最佳结果以加粗标示，可以从表2.3中看出，本章提出的 NaNREAD 算法在 10 个数据集取得了最佳的效果，Anneal、Bands、Breast、Cardio、Chess、Iono、Letter、Monk、Tic12 和 Tic26。此外，NaNREAD 在平均值指标上也达到了最优。这些结果说明 NaNREAD 在整体表现和统计意义上均具有优势。

表2.4展示了 F1 分数的实验结果，最佳结果以加粗标示，可以从表2.4中看出，本章提出的 NaNREAD 算法在 7 个数据集取得了最佳的效果，分别是 Bands、Cardio、Iono、Letter、Monk、Tic12 和 Tic26。此外，NaNREAD 在平均值指标上也达到了最优。这些结果说明 NaNREAD 在整体表现和统计意义上均具有优势。




图 2.2 ROC 指标的实验对比结果

Figure 2.2 Experimental comparison results on ROC

表 2.4 F1 分数实验评估表

Table 2.4 Experimental evaluation of F1-score

数据集	NaNREAD	SEQ	IE	ITB	WDOD	ODGrCR	ApproE	VarE	ILGNI	MFIOD	VAE
Anneal	0.2568	0.2392	0.1753	0.2157	0.1962	0.2143	0.3119	0.3095	0.1789	0.2115	0.2335
Bands	0.3636	0.1600	0.1333	0.2222	0.1667	0.2222	0.1111	0.1250	0.3636	0.2857	0.2500
Breast	0.5242	0.5196	0.5118	0.5196	0.5327	0.5023	0.4904	0.4932	0.5198	0.5024	0.4726
Cardio	0.2703	0.1017	0.1395	0.1449	0.1951	0.1231	0.1420	0.1429	0.1308	0.1212	0.2200
Chess	0.4035	0.3743	0.2406	0.3636	0.4317	0.4247	0.2400	0.2585	0.2755	0.3368	0.3019
Diabetes	0.6024	0.6154	0.6102	0.6567	0.6250	0.6316	0.7458	0.7407	0.4494	0.7667	0.2963
Glass	0.1558	0.2069	0.2745	0.1856	0.0925	0.2022	0.1379	0.1429	0.1739	0.1667	0.1333
Iono	0.9796	0.7302	0.7451	0.8636	0.8889	0.7727	0.2500	0.1818	0.9412	0.9796	0.9787
Letter	0.3017	0.1354	0.1404	0.1357	0.1188	0.1353	0.1571	0.1298	0.1784	0.1407	0.1864
Monk	1.0000	0.8571	1.0000	1.0000	0.8571	1.0000	0.3333	0.3333	1.0000	0.8571	0.8571
Pima	0.5660	0.6218	0.5333	0.6383	0.6056	0.6418	0.6796	0.6949	0.5957	0.7692	0.4969
Tic12	0.9091	0.5882	0.3333	0.4444	0.8000	0.6364	0.1023	0.0914	0.2222	0.3636	0.2750
Tic26	0.5641	0.2667	0.3030	0.2112	0.3125	0.2411	0.1465	0.1467	0.2316	0.1765	0.3297
Vowels	0.3871	0.0895	0.2414	0.0914	0.0668	0.0887	0.5455	0.2906	0.1068	0.1506	0.1299
Zoo	0.3889	0.3684	0.4286	0.4324	0.3902	0.4390	0.2957	0.4000	0.3871	0.4865	0.5143
平均值	0.5115	0.3916	0.3874	0.4084	0.4186	0.4184	0.3126	0.2987	0.3837	0.4210	0.3784
排名第一的个数	7	0	2	1	2	1	2	0	2	3	1

2.6.3 统计假设检验分析

首先使用 Friedman 检验来判断所有算法之间是否存在显著差异。如果检验结果显示存在显著性差异，则进一步进行 Nemenyi 检验，计算临界差值并绘制 Nemenyi 检验图。如果在图中一组算法之间通过水平线段连接，则表示它们之间无显著性差异。

如表2.3所示，我们在总计 15 个数据集上对 11 种算法的性能进行了比较。因此，可以得到自由度为 10 和 140 的 F 分布。根据 Friedman 检验的结果，统计量 $\tau_F = 3.7861$ 大于在显著性水平 $\alpha = 0.05$ 下的临界值 1.8989。因此，原假设“所有算法的性能相同”不成立，表明这些算法之间的性能存在显著差异。

此外，为了更好地区分这些算法，我们进一步进行了 Nemenyi 事后检验。在显著性水平 $\alpha = 0.05$ 下，计算得到的临界差值为 $CD_{0.1} = 3.8984$ 。我们在 AUC 指标上绘制了 Nemenyi 检验图，如图 2.3 所示。可以看到，图中 NaNREAD 与 SEQ、IE、ITB、WDOD、ApproE、VarE 和 ILGNI 之间没有水平线段连接，说明 NaNREAD 与这些算法在统计上存在显著差异。然而，NCNEAD 与 MFIOD、ODGrCR 以及 VAE 之间的差异在统计上尚无一致性证据支持。




图 2.3 关于 AUC 的 Nemenyi 检验图

Figure 2.3 Nemenyi's test figure on AUC

参考文献

- [1] HAWKINS D M. Monographs on statistics and applied probability: Identification of outliers [M]. Chapman & Hall/CRC, 1980.
- [2] 李毅, 胡建成. 一种面向混合属性数据的邻域粒离群点检测[J]. 小型微型计算机系统, 2020, 41(04): 855-860.
- [3] AGGARWAL C C. Outlier analysis[M]. Springer, 2016.
- [4] LIU H, LI X, LI J, et al. Efficient outlier detection for high-dimensional data[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2017, 48(12): 2451-2461.
- [5] LI J, ZHANG J, PANG N, et al. Weighted outlier detection of high-dimensional categorical data using feature grouping[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2020, 50(11): 4295-4308.
- [6] CHEN D, YANG Y. Attribute reduction for heterogeneous data based on the combination of classical and fuzzy rough set models[J]. IEEE Transactions on Fuzzy Systems, 2014, 22(5): 1325-1334.
- [7] XIA S, ZHANG H, LI W, et al. Gbnrs: A novel rough set algorithm for fast adaptive attribute reduction in classification[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(3): 1231-1242.
- [8] YASMIN G, DAS A K, NAYAK J, et al. Graph based feature selection investigating boundary region of rough set for language identification[J]. Expert Systems with Applications, 2020, 158: 113575.
- [9] CHEN H, LI T, LUO C, et al. A decision-theoretic rough set approach for dynamic data mining [J]. IEEE Transactions on Fuzzy Systems, 2015, 23(6): 1958-1970.
- [10] LIANG D C, PEDRYCZ W, LIU D. Determining three-way decisions with decision-theoretic rough sets using a relative value approach[J]. IEEE Transactions on Systems Man & Cybernetics Systems, 2016, 99(8): 1-15.
- [11] ZHANG P, LI T, WANG G, et al. Multi-source information fusion based on rough set theory: A review[J]. Information Fusion, 2021, 68: 85-117.
- [12] PRASAD M, TRIPATHI S, DAHAL K. An efficient feature selection based bayesian and rough set approach for intrusion detection[J]. Applied Soft Computing, 2020, 87: 105980.
- [13] ZHANG X, GOU H, LV Z, et al. Double-quantitative distance measurement and classification learning based on the tri-level granular structure of neighborhood system[J]. Knowledge-Based Systems, 2021, 217: 106799.
- [14] LIN T Y. Neighborhood systems and relational databases[C]//Proceedings of the 1988 ACM sixteenth annual conference on Computer science. ACM, 1988: 725.
- [15] YAO Y Y. Relational interpretations of neighborhood operators and rough set approximation operators[J]. Information Sciences, 1998, 111(1-4): 239-259.
- [16] HU Q, YU D, LIU J, et al. Neighborhood rough set based heterogeneous feature subset selection [J]. Information sciences, 2008, 178(18): 3577-3594.
- [17] HU Q, LIU J, YU D. Mixed feature selection based on granulation and approximation[J].

- Knowledge-Based Systems, 2008, 21(4): 294-304.
- [18] HU Q, YU D, XIE Z. Neighborhood classifiers[J]. Expert systems with applications, 2008, 34(2): 866-876.
 - [19] CHEN Y M, MIAO D Q, ZHANG H Y. Neighborhood outlier detection[J]. Expert Systems with Applications, 2010, 37(12): 8745-8749.
 - [20] YUAN Z, ZHANG X Y, FENG S. Hybrid data-driven outlier detection based on neighborhood information entropy and its developmental measures[J]. Expert Systems with Applications, 2018, 112: 243-257.
 - [21] WANG Y, LI Y P. Outlier detection based on weighted neighbourhood information network for mixed-valued datasets[J]. Information Sciences, 2021, 564: 396-415.
 - [22] GOH P Y, TAN S C, CHEAH W P, et al. Adaptive rough radial basis function neural network with prototype outlier removal[J]. Information Sciences, 2019, 505: 127-143.
 - [23] 冯骥. 自然邻居思想概念及其在数据挖掘领域的应用[D]. 重庆: 重庆大学, 2016.
 - [24] HU Q H, YU D R. Neighborhood entropy[C]//2009 International Conference on Machine Learning and Cybernetics: Vol. 3. 2009: 1776-1782.
 - [25] 王莹. 基于粗糙集的工程项目安全管理的多属性群决策方法[D]. 西安电子科技大学, 2020.
 - [26] 汪贝琪, 周杰, 高灿. 基于模糊邻域熵的多粒度离群点检测方法[J]. 模糊系统与数学, 2022, 36(06): 102-113.
 - [27] ZHU Q, FENG J, HUANG J. Natural neighbor: A self-adaptive neighborhood method without parameter k [J]. Pattern recognition letters, 2016, 80: 30-36.
 - [28] BREUNIG M M, KRIEGEL H P, NG R T, et al. Lof: identifying density-based local outliers [C]//Proceedings of the 2000 ACM SIGMOD international conference on Management of data. 2000: 93-104.
 - [29] JIANG F, SUI Y F, CAO C G. Some issues about outlier detection in rough set theory[J]. Expert Systems with Applications, 2009, 36(3): 4680-4687.
 - [30] JIANG F, SUI Y F, CAO C G. An information entropy-based approach to outlier detection in rough sets[J]. Expert Systems with Applications, 2010, 37(9): 6338-6344.
 - [31] WU S, WANG S. Information-theoretic outlier detection for large-scale categorical data[J]. IEEE Transactions on Knowledge and Data Engineering, 2013, 25(3): 589-602.
 - [32] ZHAO X, LIANG J, CAO F. A simple and effective outlier detection algorithm for categorical data[J]. International Journal of Machine Learning & Cybernetics, 2014, 5(3): 469-477.
 - [33] JIANG F, CHEN Y M. Outlier detection based on granular computing and rough set theory [J]. Applied Intelligence, 2015, 42(2): 303-322.
 - [34] LI X, LV J, YI Z. Outlier detection using structural scores in a high-dimensional space[J]. IEEE Transactions on Cybernetics, 2020, 50(5): 2302-2310.
 - [35] LI R, CHEN H, LIU S, et al. Incomplete mixed data-driven outlier detection based on local-global neighborhood information[J]. Information Sciences, 2023, 633: 204-225.
 - [36] CHEN B, LI Y, PENG D, et al. Fusing multi-scale fuzzy information to detect outliers[J]. Information Fusion, 2024, 103: 102133.
 - [37] KINGMA D P, WELING M. Auto-encoding variational bayes[A]. 2014.